Laporan Praktikum 4: Association Rule (Apriori dan FP-Growth)

Zico Diego Rio Ramadhonny (5054251023)

1. Pendahuluan

Association rule mining adalah teknik data mining untuk menemukan pola keterkaitan antar item dalam sekumpulan transaksi. Contoh paling umum adalah *market basket analysis*, yaitu mencari tahu produk apa saja yang cenderung dibeli bersamaan. Pada praktikum ini, dua algoritma digunakan untuk menemukan *frequent itemset* dan membentuk aturan asosiasi dari data transaksi ritel, yaitu **Apriori** dan **FP-Growth**, dengan bantuan pustaka `mlxtend`.

2. Tujuan

1. Menyiapkan data transaksi ritel menjadi format keranjang belanja (*basket*) biner yang siap diproses.
2. Menerapkan algoritma Apriori dan FP-Growth untuk mencari aturan asosiasi.
3. Membandingkan hasil kedua algoritma dan menginterpretasikan aturan dengan nilai *lift* tertinggi.

3. Dataset

Dataset yang digunakan adalah **Online Retail** dari UCI Machine Learning Repository, diunduh otomatis dari notebook dalam bentuk file zip lalu dibaca dengan `pd.read_excel`.

Hasil eksplorasi awal (*initial EDA*):

Aspek	Nilai
Jumlah baris	541.909
Jumlah kolom	8
Kolom	InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country

Aspek	Nilai
Rentang tanggal transaksi	1 Desember 2010 sampai 9 Desember 2011
Nilai kosong pada Description	1.454 baris
Nilai kosong pada CustomerID	135.080 baris

Statistik deskriptif menunjukkan adanya nilai tidak wajar. `Quantity` memiliki nilai minimum -80.995 dan `UnitPrice` memiliki nilai minimum -11.062,06. Nilai negatif ini umumnya berasal dari pembatalan atau penyesuaian transaksi, sehingga perlu dibersihkan sebelum analisis.

4. Metodologi dan Praproses Data

Tahapan yang dilakukan pada notebook adalah sebagai berikut.

1. **Memilih fitur relevan.** Hanya kolom `InvoiceNo`, `StockCode`, `Description`, dan `Quantity` yang dipertahankan. Kolom `InvoiceDate`, `UnitPrice`, `CustomerID`, dan `Country` dibuang karena tidak diperlukan untuk analisis keranjang belanja.
2. **Memperbaiki tipe data.** Kolom `InvoiceNo`, `StockCode`, dan `Description` diubah menjadi string, sedangkan `Quantity` menjadi integer.
3. **Membuang baris tidak valid.** Baris dengan `Quantity` ≤ 0, baris dengan `InvoiceNo` berawalan huruf "C" (faktur pembatalan), dan baris dengan nilai kosong dibuang. Jumlah baris turun dari **541.909** menjadi **530.693** (11.216 baris dibuang).
4. **Membuang fitur redundan.** Kolom `Quantity` dan `Description` dibuang, sehingga tersisa `InvoiceNo` dan `StockCode`.
5. **Transformasi ke format basket.** Dengan `pd.crosstab` antara `InvoiceNo` dan `StockCode` lalu dikonversi ke boolean, diperoleh matriks transaksi biner (*one-hot encoding*) berukuran **20.136 transaksi × 3.925 item unik**.
6. **Pemodelan.** Apriori dan FP-Growth dijalankan dengan parameter berikut.

Parameter	Nilai
Minimum support	0,01 (1%)
Minimum confidence	0,5 (50%)
Metrik pembentukan rule	confidence

Parameter	Nilai
Pengurutan hasil	lift, lalu confidence, lalu support (menurun)

Dengan 20.136 transaksi, ambang support 0,01 berarti sebuah itemset harus muncul pada sekitar 202 transaksi atau lebih.

Sebelum kolom `Description` dibuang, dibuat kamus `stock_desc_map` (StockCode ke Description) agar kode produk pada hasil aturan dapat diterjemahkan menjadi nama produk. Waktu eksekusi diukur dengan `time.time()` mulai dari sebelum algoritma dijalankan sampai aturan asosiasi terbentuk.

5. Hasil

5.1 Jumlah aturan yang dihasilkan

Baik Apriori maupun FP-Growth menghasilkan **937 aturan asosiasi**. Nilai *lift* terbesar adalah sekitar 80,22 dan yang terkecil sekitar 4,82, sehingga seluruh aturan yang lolos menunjukkan hubungan positif yang kuat (lift jauh di atas 1).

5.2 Tiga aturan teratas (berdasarkan lift)

Kedua algoritma menghasilkan tiga aturan teratas yang identik.

No	Antecedent	Consequent	Support	Confidence	Lift
1	HERB MARKER ROSEMARY (22917), HERB MARKER PARSLEY (22918)	HERB MARKER THYME (22916)	0,010081	0,9442	80,22
2	HERB MARKER THYME (22916)	HERB MARKER ROSEMARY (22917), HERB MARKER PARSLEY (22918)	0,010081	0,8565	80,22
3	HERB MARKER ROSEMARY (22917)	HERB MARKER THYME (22916), HERB MARKER PARSLEY (22918)	0,010081	0,8458	79,96

Aturan berikutnya di urutan atas masih berasal dari kelompok produk yang sama, misalnya {HERB MARKER THYME, HERB MARKER PARSLEY} → {HERB MARKER ROSEMARY} (confidence 0,9531, lift 79,96) dan {HERB MARKER THYME} → {HERB MARKER ROSEMARY} (support 0,010975, confidence 0,9325, lift 78,24).

5.3 Aturan dengan lift terendah

Beberapa aturan di ujung bawah daftar, yang masih memenuhi ambang confidence 0,5, antara lain:

Antecedent	Consequent	Support	Confidence	Lift
PINK REGENCY TEACUP AND SAUCER (22698)	REGENCY CAKESTAND 3 TIER (22423)	0,019468	0,5117	5,18
SUKI SHOULDER BAG (21935)	JUMBO BAG RED RETROSPOT (85099B)	0,014005	0,5321	5,12
GREEN REGENCY TEACUP AND SAUCER (22697)	REGENCY CAKESTAND 3 TIER (22423)	0,025278	0,5015	5,08
TOY TIDY PINK POLKADOT (22381)	JUMBO BAG RED RETROSPOT (85099B)	0,012118	0,5203	5,01
RED RETROSPOT SHOPPER BAG (20718)	JUMBO BAG RED RETROSPOT (85099B)	0,014303	0,5009	4,82

Aturan-aturan ini memiliki support lebih tinggi tetapi lift lebih rendah. REGENCY CAKESTAND 3 TIER dan JUMBO BAG RED RETROSPOT berulang sebagai consequent, yang menandakan keduanya produk populer yang sering muncul bersama berbagai produk lain, misalnya cangkir dan piring teh bertema Regency, atau tas belanja bertema Red Retrospot.

5.4 Waktu eksekusi

Algoritma	Waktu (detik)	Jumlah aturan
Apriori	18,78	937
FP-Growth	85,30	937

Waktu mencakup pencarian *frequent itemset* dan pembentukan aturan (`association_rules`), tidak termasuk pengurutan dan pemetaan nama produk. Pada percobaan ini Apriori sekitar 4,5 kali lebih cepat daripada FP-Growth.

6. Analisis dan Pembahasan

Kesamaan hasil Apriori dan FP-Growth. Kedua algoritma menemukan himpunan *frequent itemset* yang sama persis untuk parameter yang sama, sehingga jumlah aturan (937) dan urutan aturan teratasnya identik. Ini sesuai teori: perbedaan keduanya terletak pada cara pencarian, bukan pada hasilnya. Apriori membangkitkan kandidat itemset secara bertahap dan memindai data berulang kali, sedangkan FP-Growth membangun struktur FP-Tree yang dipadatkan.

Perbedaan waktu eksekusi. Hasil pengukuran berlawanan dengan harapan umum bahwa FP-Growth lebih cepat: Apriori selesai dalam 18,78 detik, sedangkan FP-Growth membutuhkan 85,30 detik. Beberapa kemungkinan penyebab, yang belum diuji pada praktikum ini: (1) minimum support 1% cukup tinggi sehingga hanya sedikit item yang lolos dan pemangkasan Apriori bekerja efektif; (2) implementasi FP-Growth di `mlxtend` dijalankan pada DataFrame boolean padat dengan 3.925 kolom; (3) hasil berasal dari satu kali eksekusi sehingga dapat dipengaruhi kondisi komputer. Pengulangan eksperimen dan variasi nilai minimum support diperlukan sebelum menarik kesimpulan umum tentang efisiensi.

Interpretasi aturan teratas. Produk HERB MARKER THYME (22916), HERB MARKER ROSEMARY (22917), dan HERB MARKER PARSLEY (22918) sangat sering dibeli bersamaan. Pada aturan 1, jika pelanggan membeli Rosemary dan Parsley, sekitar 94,4% transaksi tersebut juga memuat Thyme. Nilai lift sekitar 80 berarti peluang Thyme muncul pada transaksi yang memuat Rosemary dan Parsley kira-kira 80 kali lebih besar dibandingkan peluang kemunculannya secara acak. Ketiganya adalah penanda tanaman herba satu seri, sehingga wajar dibeli sebagai satu set.

Pasangan aturan simetris. Banyak aturan muncul berpasangan dengan nilai support dan lift yang sama tetapi confidence berbeda (misalnya aturan 1 dan 2). Hal ini wajar karena lift bersifat simetris, sedangkan confidence bergantung pada arah aturan.

Support, confidence, dan lift. Support rendah (sekitar 1%) pada aturan teratas menunjukkan bahwa pola ini terjadi pada sebagian kecil transaksi, tetapi sangat konsisten ketika terjadi. Sebaliknya, aturan dengan support lebih tinggi cenderung punya lift lebih rendah karena melibatkan produk populer yang memang sering muncul di banyak transaksi.

7. Keterbatasan dan Saran

1. **Pemetaan nama produk belum sempurna.** `stock_desc_map` menyimpan satu deskripsi per StockCode (yang terakhir ditemui), padahal satu kode dapat memiliki beberapa variasi nama. Urutan nama dalam list juga tidak tetap karena berasal dari `tuple(frozenset)`; gunakan `sorted()` agar konsisten.
2. **Kode non-produk masih ada.** Matriks basket memuat kode seperti `POST`, `M`, `m`, `PADS`, `S`, dan `gift_...` yang bukan produk biasa (misalnya ongkos kirim, input manual, voucher). Selain itu, indeks transaksi memuat faktur berawalan huruf "A" (misalnya A563187) yang tampaknya merupakan faktur penyesuaian. Kode dan faktur seperti ini sebaiknya disaring agar tidak mengganggu aturan.
3. **Ambang support relatif tinggi.** Dengan 3.925 item unik, minimum support 1% hanya menangkap produk dan kombinasi yang cukup populer. Pola pada produk niche tidak akan terdeteksi. Pengujian dengan ambang lebih rendah, misalnya 0,5%, dapat memperkaya hasil, dengan konsekuensi kebutuhan memori dan waktu yang lebih besar. Notebook sudah menyiapkan (dalam bentuk komentar) filter item berdasarkan support untuk menjaga penggunaan memori, namun tidak diaktifkan.
4. **Perbandingan waktu baru dari satu kali eksekusi.** Disarankan mengulang pengukuran beberapa kali pada berbagai nilai minimum support, dan membandingkan dengan input DataFrame sparse, untuk memastikan penyebab FP-Growth lebih lambat dari Apriori.
5. **Metrik tambahan.** Selain support, confidence, dan lift, metrik seperti leverage dan conviction dapat dipertimbangkan untuk menilai kekuatan aturan.

8. Kesimpulan

1. Praproses menghasilkan 530.693 baris valid yang diubah menjadi matriks basket biner berukuran 20.136 transaksi × 3.925 item.
2. Dengan minimum support 0,01 dan minimum confidence 0,5, Apriori dan FP-Growth sama-sama menghasilkan 937 aturan asosiasi dengan hasil identik, termasuk tiga aturan teratas.
3. Aturan terkuat melibatkan HERB MARKER THYME, ROSEMARY, dan PARSLEY dengan lift sekitar 80 dan confidence hingga sekitar 95%, yang menunjukkan ketiganya hampir selalu dibeli bersamaan.
4. Pada percobaan ini Apriori (18,78 detik) lebih cepat daripada FP-Growth (85,30 detik), berlawanan dengan harapan umum. Penyebabnya perlu diuji lebih lanjut dengan pengulangan dan variasi parameter.

5. Hasil ini dapat dimanfaatkan untuk strategi *bundling*, penempatan produk berdekatan, atau rekomendasi produk. Kualitas aturan dapat ditingkatkan dengan menyaring kode non-produk.